

AutoEncoder, Variational

Goal: To maximize $\log P(x)$

(if $P(x)$ is high, it is more likely to generate data similar to the observed x .)

$$1. P(x) = \int P(x|z)P(z) dz \rightarrow \text{전체 z에 대해}$$

$$\log P(x) = \log \int P(x|z)P(z) dz$$

Problem: We cannot integral over all latent var z , impossible.

$P(x|z)$ Complexity가 너무 높고 z 도 Potentially high-dimensional.

Ans: approx ~~$P(z|x)$~~ $P(z|x)$ → 데이터를 만드는 방식.

$$P(z|x) = \frac{P(x|z)P(z)}{P(x)}, \quad P(x) = \int P(x|z)P(z) dz$$

Goal: $\log P(x) \approx \mathbb{E}_{q_\phi(z|x)} \log P(x|z)$ 이 대해 expectation 되게 하자.

이렇게 하면 $P(x)$ 를 tractable 하게 만들 수 있다. approx된 것을 expectation 해주면 되니까.

$$\log P(x) = \log \int \frac{P(x|z)P(z)}{q_\phi(z|x)} \cdot q_\phi(z|x) dz$$

$$\log P(x) = \log \int \frac{P(x, z)}{q_\phi(z|x)} q_\phi(z|x) dz$$

우자

$q_\phi(z|x)$ 가 알기

불은 expectation을
생각 가능.

$$\log P(x) = \log E_{q_\phi(z|x)} \left[\frac{P(x, z)}{q_\phi(z|x)} \right]$$

Now, tractable.

Jensen's inequality to obtain ELBO.

\log 가 Concave이기 때문에 Jensen's inequality 적용 가능

* Jensen's inequality (볼록함수일 때만 성립하는 부등식)

$$E(g(x)) \geq g(E(x))$$

볼록함수일 경우 (Convex)

$$E(g(x)) \leq g(E(x))$$

\log 는 Concave이기 때문에

$$\log P(x) \geq E_{q_\phi(z|x)} \left[\log \frac{P(x, z)}{q_\phi(z|x)} \right]$$

\log 가 g 함수라고
생각.

This is ELBO.

$$\log P(x) \geq E_{q_{\phi}(z|x)} \left[\log \frac{P(x, z)}{q_{\phi}(z|x)} \right]$$

$$\log \frac{P(x|z)P(z)}{q_{\phi}(z|x)} = \log P(x|z) + \log P(z) - \log q_{\phi}(z|x)$$

$$\geq E_{q_{\phi}(z|x)} \left[\log P(x|z) + \log P(z) - \log q_{\phi}(z|x) \right]$$

Reconstruction
term.
Z의 x를 얼마나
잘 생성해내는지.

★ (Z에 대한 KL divergence)
를 동일하다.

★ KL divergence.

q(z) expectation을 P(z)에
대해 expectation을 하는 것

$$KL(q_{\phi}(z|x) \parallel P(z)) = E_{q_{\phi}(z|x)} \left[\log \frac{q_{\phi}(z|x)}{P(z)} \right]$$

$$* KL(P \parallel Q) = \sum_i P_i \log \frac{P_i}{Q_i} \quad \text{or} \quad \sum_i P_i \log \frac{Q_i}{P_i}$$

(discrete)

$$= \int P(x) \log \frac{P(x)}{Q(x)} dx \quad \text{or} \quad \int P(x) \log \frac{Q(x)}{P(x)} dx$$

(continuous)

So, $\log P(x) \geq \text{ELBO}$

$$\geq E_{q_{\phi}(z|x)} [\log P(x|z)] - \text{KL}(q_{\phi}(z|x) || p(z))$$



Regularization term

why? $q_{\phi}(z|x)$ 중

$p(z)$ 중 비슷한 분포를

가져가게 한다.

왜 디자인했.

So,

$\max_{\phi} \text{ELBO}$

ϕ

이 ELBO를 maximize

하는 ϕ 를 (NN params)

찾는 것이다.

So, full VAE process.

1. Define Model architecture and Distribution

encoder: $q_{\phi}(Z|x)$, 그리고 $\mu(x)$ 와 $\sigma^2(x)$ 를 뽑는다.

decoder: Z 를 data space로, $p(x|Z)$ 를.

우리 데이터가 어떻게 생겼다고 가정할까? ($p(x|Z)$ assumption)

Continuous: Gaussian (이미지 일 경우)

Discrete: Bernoulli (0, 1 일 경우)

$P(Z)$, prior dist. 는 보통 $N(0, I)$ 로 정해.

I 가 identity I 인 이유는

2. Forward Pass

Z 가 multi-dim 이미지

I : ~~matrix~~

Identity Covariance.

이미지 x 를 encoder에 넣어

$\mu(x)$, $\sigma^2(x)$ 를 뽑는다.

Reparameter trick: $q_{\phi}(Z|x) = N(\mu, \sigma^2)$ 로부터 바로

Z 를 샘플링 하지 않고, $Z = \mu(x) + \sigma(x) \cdot \sum \epsilon \sim N(0, I)$

로 해서 Sampling Process를 피하게끔 하겠다.

그래서 ϵ 도 잘 가늠해야겠다.

typical Sampling, Not differentiable.

So we got some z s.

Sample된 z 를 decoder network의 용이서 $P(x|z)$ 를 통해
실려.

Maximize elbo :

$$\max_{\phi} E_{q_{\phi}(z|x)} [\log p(x|z)] - KL(q_{\phi}(z|x) || p(z))$$

* KL Annealing (optional)

KL term이 dominate 할 수 있는 것을 방지. 이를

$$E_{q_{\phi}(z|x)} [\log p(x|z)] - \beta KL(q_{\phi}(z|x) || p(z))$$

방향이 있다.

* Allows initial focus

on reconstruction,

β 는 0 ~ 1 증가
정해진

gradually regularize latent space.

Backprop. $\frac{\partial}{\partial \theta}$

About mean-field and Variational Flow.

일반 $p(x|z)$ 도 Gaussian 이라고 가정 (이러지 않으면 연속적이지 않을 때)

' $q(z|x)$ ' 가 Posterior 이고. 이를 Approximate Posterior.

$p(z|x)$, true posterior는 unknown 이고 highly complex.

Basic VAE에서는 $q(z|x)$ 도 Simple Gaussian 이
encoder 가 주는 mean, var 이 parameter를 생략.

이를 mean-field Gaussian approximation 이다.

$$q(z|x) \sim \mathcal{N}(\mu(x), \text{diag}(\sigma(x)^2))$$

→ Too restrictive

each dimension of z is independent given x .

그러나 complex dependency capture이 어렵다.

해결방향이 normalizing flows.

simple
Gaussian 을

more complex dist.로 변환하는 작업이다.

$p(z|x)$ 의
형태를 더 복잡

Variational Flow

1. Start with $Z_0 \sim N(0, I)$ (Simple Gaussian)

2. Apply series of transformations.

$$f_1, f_2, \dots, f_k$$

$$Z_k = f_k \circ f_{k-1} \circ \dots \circ f_1(Z_0)$$

$$3. \quad q(Z_k | x) = q(Z_0) \prod_{i=1}^k \left| \det \frac{\partial f_i}{\partial Z_{i-1}} \right|^{-1}$$

↪ Jacobian determinant.

* How transformations stretch
or compress space,
altering the probability
density